Taller de drivers

Sistemas Operativos

Departamento de Computación
Facultad de Ciencias Exactas y Naturales
Universidad de Buenos Aires

11 de Mayo de 2023

Tabla de Contenidos

Tabla de Contenidos

¿Qué vimos?

- Primera parte de la materia:
  - Syscalls
  - Scheduling
  - IPC (y threads)
  - Memoria
- Segunda parte de la materia:
  - Entrada / Salida (orga 1) y Repaso de diseño E/S
  - Drivers
- ¿Con qué están atrazados? ☺
  - Práctica de E/S
  - TP

Tabla de Contenidos

¿Qué vamos a hacer hoy?

Hoy vamos a aprender a hacer un driver.

- ¿Qué es un driver?

`subsistema-es.pdf`

¿Qué es un driver?

- Un dispositivo de E/S va a tener, conceptualmente, dos partes:
  - El dispositivo físico.
  - Un controlador del dispositivo que interactúa con el SO mediante algún tipo de bus o registro.
- Los drivers son componentes de software muy específicos. Conocen las particularidades del HW contra el que hablan.

¿Los drivers son parte del SO? (1)

- Cuando enciendo la computadora, se carga el kernel del SO.
- Luego se cargan los distintos *módulos*, entre ellos, los drivers.
  - Administrador de memoria
  - Administrador de procesos (scheduler, etc.)
  - Sistema de archivos
  - Driver del teclado
  - Dirver del mouse
  - Driver de video
  - Driver de ...

¿Los drivers son parte del SO? (2)

- Necesito un driver nuevo.
  - ¿Ya existía el código en el kernel?
  - ¿Tengo que reiniciar la máquina y cargar de nuevo el kernel?
  - ¿Tengo que recompilar el kernel?

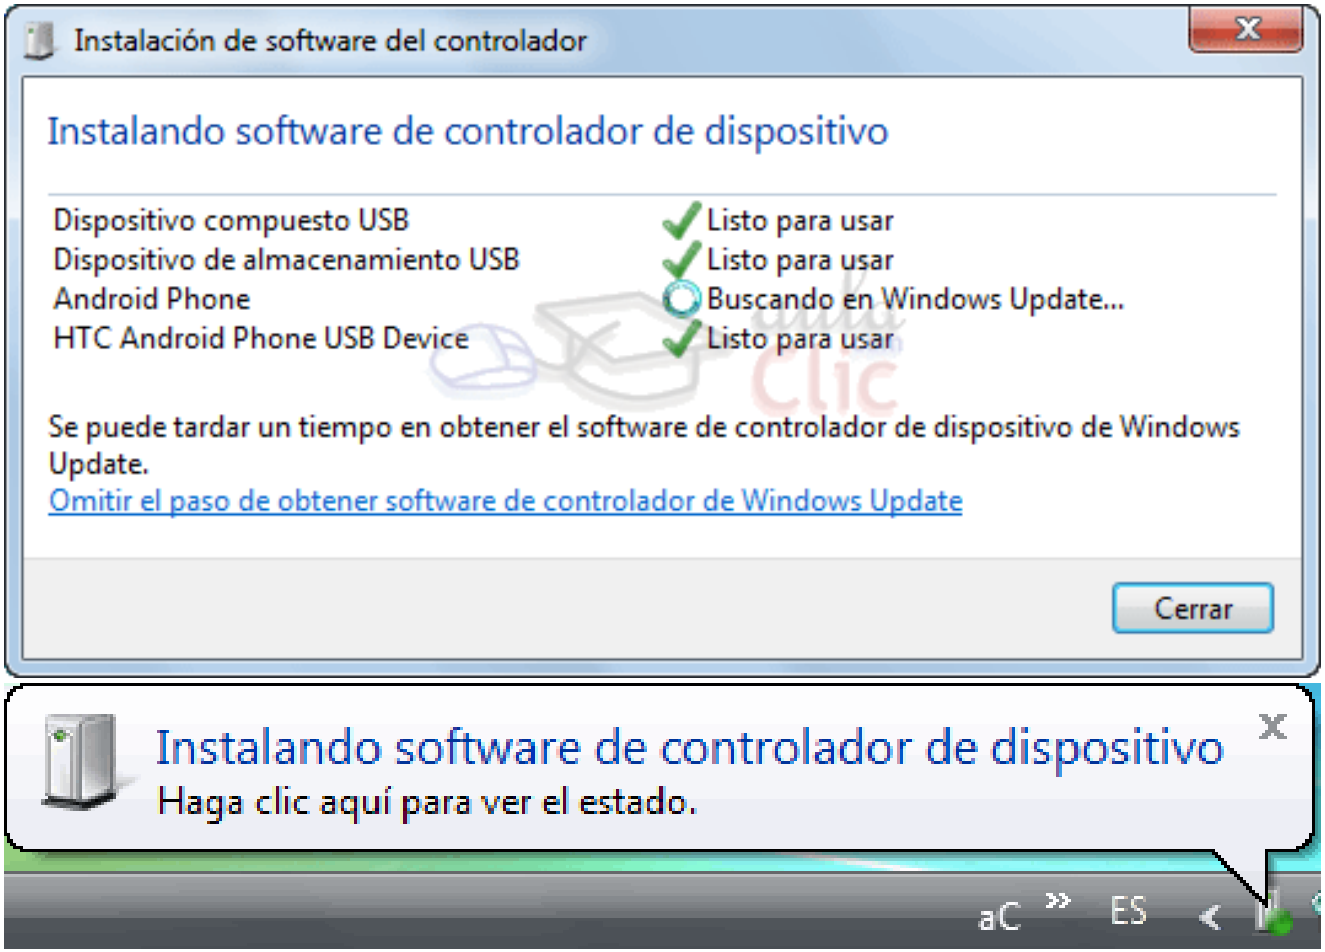

Solución

Si el kernel está todo contenido en **un** gran archivo binario:

- ¿Qué pasa si quiero agregar funcionalidad cuando ya estoy usando la máquina?
- ¿Qué pasa si incluyo funcionalidad "por las dudas"?

Solución: (de linux)
Linux soporta la carga y descarga de **módulos** al kernel en tiempo de ejecución.

Tabla de Contenidos

Módulos

- ¿Qué cosas componen a un **módulo**?
  - Puntos de entrada y salida
  - Datos
  - Funciones
- ¿A causa de qué podría ejecutarse el código de un módulo?
  1. Llamada al sistema
  2. Atención de interrupción
- ¿Qué funcionalidades podría brindar un módulo?
- Hoy vamos a escribir nuestro primer módulo...

Un nuevo mundo...

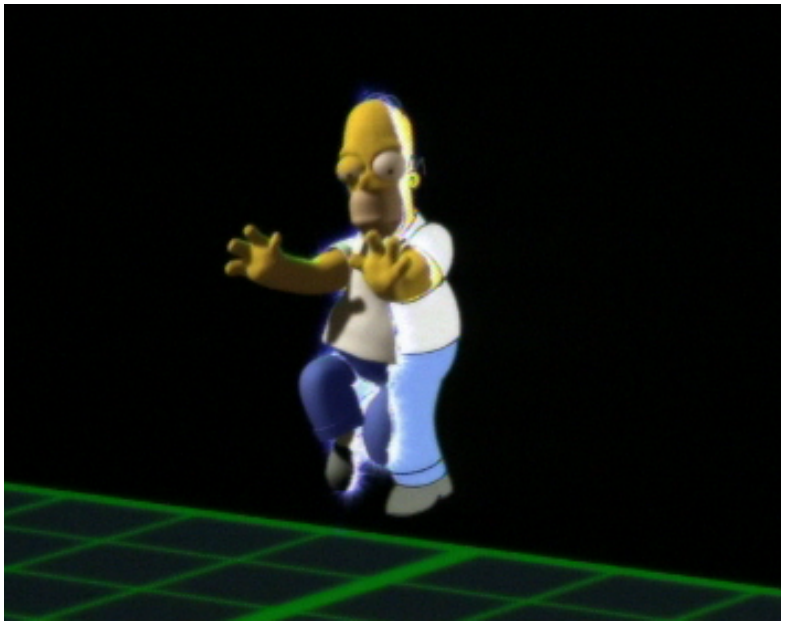

- Estamos ejecutando en el **nivel de máximo privilegio**
- El kernel no está enlazado a la `libc`
- Hacer **operaciones de punto flotante** es más complicado
- Tenemos un **stack fijo y limitado** (y tenemos que compartirlo con el resto del kernel)
- Hay varias fuentes de posibles **condiciones de carrera**
- ¿Qué pasa si hacemos un **acceso indebido a memoria**?


DANGER

Nuestro primer módulo (1)

```
#include <linux/init.h>
#include <linux/module.h>
#include <linux/kernel.h>

static int __init hello_init(void) {
  printk(KERN_ALERT "Hola, Sistemas Operativos!\n");
  return 0;
}

static void __exit hello_exit(void) {
  printk(KERN_ALERT "Adios, mundo cruel...\n");
}

module_init(hello_init);
module_exit(hello_exit);

MODULE_LICENSE("GPL");
MODULE_AUTHOR("Juan de los Palotes");
MODULE_DESCRIPTION("Una suerte de 'Hola, mundo'");
```

Nuestro primer módulo (2)

```
#include <linux/init.h>
#include <linux/module.h>
#include <linux/kernel.h>
```

- `init.h` contiene la definición de las macros `module_init()` y `module_exit()`
- `module.h` contiene varias definiciones necesarias para la gran mayoría de los módulos (por ejemplo, varios `MODULE_*`)
- `kernel.h` contiene la declaración de `printk()`

Nuestro primer módulo (3)

```
MODULE_LICENSE("GPL");
MODULE_AUTHOR("Juan de los Palotes");
MODULE_DESCRIPTION("Una suerte de 'Hola, mundo'");
```

- `MODULE_AUTHOR()` y `MODULE_DESCRIPTION()` son meramente informativos
- `MODULE_LICENSE()` indica la licencia del módulo;
  - algunos valores posibles son:
    - `GPL`
    - `Dual BSD/GPL`
    - `Proprietary`
  - un módulo con una licencia propietaria "mancha" el kernel

Nuestro primer módulo (4)

```
static int __init hello_init(void) {
  printk(KERN_ALERT "Hola, Sistemas Operativos!\n");
  return 0;
}

module_init(hello_init);
```

- `static` indica que la función es local al archivo (opcional)
- `__init` le indica al kernel que la función sólo se usará al momento de la inicialización, y que puede olvidarla una vez cargado el módulo (opcional)
- `printk()` se comporta de manera similar a la función `printf()` de la *libc*, pero permite indicar niveles de prioridad:
  - `KERN_ALERT` – problema de atención inmediata
  - `KERN_INFO` – mensaje con información
  - `KERN_DEBUG` – mensaje de *debug*

Nuestro primer módulo (5)

```
static int __init hello_init(void) {
  printk(KERN_ALERT "Hola, Sistemas Operativos!\n");
  return 0;
}

module_init(hello_init);
```

- Con `module_init()` se indica dónde encontrar la **función de inicialización** del módulo
- La función de inicialización es llamada:
  - al arrancar el sistema
  - al insertar el módulo
- Su rol es registar recursos, inicializar hardware, reservar espacio en memoria para estructuras de datos, etc.
- Si todo salió bien, tiene que devolver 0; si no, tiene que volver atrás lo que cambió y devolver algo distinto de cero.

Nuestro primer módulo (6)

```
static void __exit hello_exit(void) {
  printk(KERN_ALERT "Adios, mundo cruel...\n");
}

module_exit(hello_exit);
```

- Con `module_exit()` se indica dónde encontrar la **función de "limpieza"** del módulo
- La función de "limpieza" es llamada antes de quitar el módulo
- Se ocupa de deshacer/limpiar todo lo que la función de inicialización y el resto del módulo usaron

Compilando nuestro módulo

1. Necesitamos (en la vm ya está instalado).
   - `make`
   - `module-init-tools`
   - `linux-headers-<version>`
     (`<version>` sale de `uname -r`)
2. crear un Makefile con el siguiente contenido:

```
obj-m := hello.o
KVERSION := $(shell uname -r)

all:
    make -C /lib/modules/$(KVERSION)/build SUBDIRS=$(shell pwd) modules

clean:
    make -C /lib/modules/$(KVERSION)/build SUBDIRS=$(shell pwd) clean
```

3. ejecutar `make clean` y `make`

Ejecutando nuestro módulo

- Ya lo compilamos, ¿Cómo lo ejecutamos?
- `ls`
  - `hello.c hello.ko hello.mod.c hello.mod.o hello.o Makefile modules.order Modules.symvers`
- Los módulos no los ejecutamos nosotros, se ejecutan:
  1. Al cargarlo en el sistema
  2. Cuando se ejecuta una llamada al sistema
  3. Cuando se atiende una rutina de atención de interrupción
  4. Al descargarlo del sistema
- Ok, carguemos el módulo en el sistema.

Cargando módulos al kernel (1)

¿Cómo cargamos nuestro módulo al kernel?

- `insmod` carga el código y los datos de nuestro módulo al kernel
- el kernel usa su tabla de símbolos para enlazar todas las referencias no resueltas del módulo
- una vez cargado, se llama a su función de inicialización
- `rmmod` permite quitar el módulo del kernel si esto es posible (por ejemplo, falla si el módulo está siendo usado)
- `modprobe` es una alternativa más inteligente que `insmod` y `rmmod` (tiene en cuenta dependencias entre módulos)
- `lsmod` lista los módulos cargados

Cargando módulos al kernel (2)

- `sudo insmod hello.ko`
- `lsmod | grep hello`
- `sudo rmmod hello`
- `lsmod | grep hello`

Genial, ya sabemos escribir, compilar y cargar módulos pero ¿qué pasó con los drivers?

Tabla de Contenidos

Tipos de *devices*

Dijimos que los drivers se comunican con los dispositivos. ¿De qué tipo pueden ser esos dispositivos? En UNIX, comúnmente:

- **char devices**
  - pueden accederse como una tira de bytes
  - suelen no soportar *seeking*
  - se los usa directamente mediante un nodo en el filesystem
  - tienen un subtipo interesante: **misc devices**
- **block devices**
  - direccionables de a "cachos" definidos
  - suelen soportar *seeking*
  - generalmente, su nodo es montado como un filesystem
- **network devices**
  - proveen acceso a una red
  - no son accedidos a través de un nodo en el filesystem, sino de otra manera (usando sockets, por ejemplo)

Devices y Drivers

Con `ls -l /dev` podemos ver los *drivers* del sistema.

```
lrwxrwxrwx  1 root root           3 2010-10-08 20:00 cdrom -> sr0
...
crw-rw-rw-  1 root root      1,   8 2010-10-08 20:00 random
...
brw-rw----  1 root disk      8,   0 2010-10-08 20:00 sda
brw-rw----  1 root disk      8,   1 2010-10-08 20:00 sda1
...
```

El primer caracter de cada línea representa el tipo de archivo:

- `l` es un *symlink* (enlace simbólico)
- `c` es un *char device*
- `b` es un *block device*

Los *devices* tienen un par de números asociados:

- **major**: está asociado a un driver en particular
- **minor**: identifica a un dispositivo específico que el driver maneja

Construcción de un *char device*

1. Conseguir los *device numbers* (el *major* y el *minor*)
2. Definir las funciones de cada operación del *device*
3. Inicializar el *device* como un *char device*
4. Registrar el *device* como un *char device*
5. Crear un nodo en el filesystem para interactuar con el *device*

¿En qué parte del módulo se hace todo esto?

(1) Conseguir los *device numbers*

¿Cómo reservamos los *device numbers* que necesitamos?

- Asignamos uno específico (puede ser problemático)
- Pedimos al kernel que nos asigne uno dinámicamente

Para reservarlos y liberarlos dinámicamente tenemos:

```
int alloc_chrdev_region(dev_t *dev, unsigned int firstminor,
    unsigned int count, char *name);

void unregister_chrdev_region(dev_t first, unsigned int count);
```

Recibe:

- `dev_t *dev`: parámetro de salida (una estructura en donde se van a guardar los *device numbers*)
- `unsigned int firstminor`: primer *minor* a ser usado (0)
- `unsigned int count`: cantidad de *device numbers* contiguos (1)
- `char *name`: nombre del device asociado al rango

(2) Definir las operaciones (1)

```
struct file_operations {
  struct module *owner;
    ...
  ssize_t (*read) (struct file *, char __user *, size_t, loff_t *);
  ssize_t (*write) (struct file *, const char __user *, size_t,
        loff_t *);
    ...
}
```

- la estructura `file_operations` representa las operaciones que las aplicaciones pueden realizar sobre los *devices*
- cada campo apunta a una función en nuestro módulo que se encarga de la operación, o es `NULL`
- si el campo es `NULL` tiene lugar una operación por omisión distinta para cada campo

(2) Definir las operaciones (2)

```
struct file_operations {
  struct module *owner;
    ...
  ssize_t (*read) (struct file *, char __user *, size_t, loff_t *);
  ssize_t (*write) (struct file *, const char __user *, size_t,
        loff_t *);
    ...
}
```

- `owner`: un puntero al módulo "dueño" de la estructura (generalmente `THIS_MODULE`)
- `read()`: para recibir datos desde el *device*; retorna el número de bytes leídos
- `write()`: para enviar datos al *device*; retorna el número de bytes escritos

(3) Inicializar el *char device*

- el kernel representa internamente a los *char devices* mediante la estructura `struct cdev`

```
#include <linux/cdev.h>

struct cdev hello_dev;
```

- antes de que el kernel llame a nuestras operaciones, tenemos que inicializar y registrar al menos una de estas estructuras
- Llamar a la función `cdev-init` en el init

```
void cdev_init(struct cdev *cdev, struct file_operations *fops);
```

(4) Registrar el *char device* (2)

Ahora, registramos con:

```
int cdev_add(struct cdev *dev, dev_t num, unsigned int count);
```

Tener en cuenta que:

- `cdev_add()` puede fallar
- si no falló, las operaciones de nuestro módulo ya pueden ser llamadas

Para quitar al *char device* del sistema, usar:

```
void cdev_del(struct cdev *dev);
```

Módulo terminado

Listo, ya creamos el módulo, definimos sus funciones y lo registramos como un driver de dispositivo.

Ahora ¿cómo probamos el código?

Necesitamos una interfaz para que los programas de usuario puedan acceder al código.

(5) Crear nodos (1)

Tenemos, a priori, dos opciones:

- Crear los nodos, una vez se haya insertado el módulo, usando `mknod <nodo> c <major> <minor>` ,
- Que desde el módulo se genere algún tipo de aviso a alguien, en espacio de usuario, que se encargue de crear el nodo

Para lo segundo:

```
#include <linux/device.h>

static struct class *hello_class;

hello_class = class_create(THIS_MODULE, "hello");
device_create(hello_class, NULL, hello_devno, NULL, "hello");

device_destroy(hello_class, hello_devno);
class_destroy(hello_class);
```

(5) Crear nodos (2)

- La próxima vez que carguemos nuestro módulo, se generará un nuevo dispositivo virtual en `/dev/`.
- Podemos verlo con `ls /dev/ | grep hello`
  - El nombre con el que figura es el que le dieron al llamar a `device_create`, podría ser distinto al nombre del módulo.
- Para leer el dispositivo:
  - `sudo head -n 1 /dev/hello`
- Para escribir el dispositivo:
  - `echo -n "1"| sudo tee /dev/hello`

Tabla de Contenidos

Antes de empezar el taller...

- Descargar y configurar la VM de la materia.
- Descargar instrucciones desde el campus.

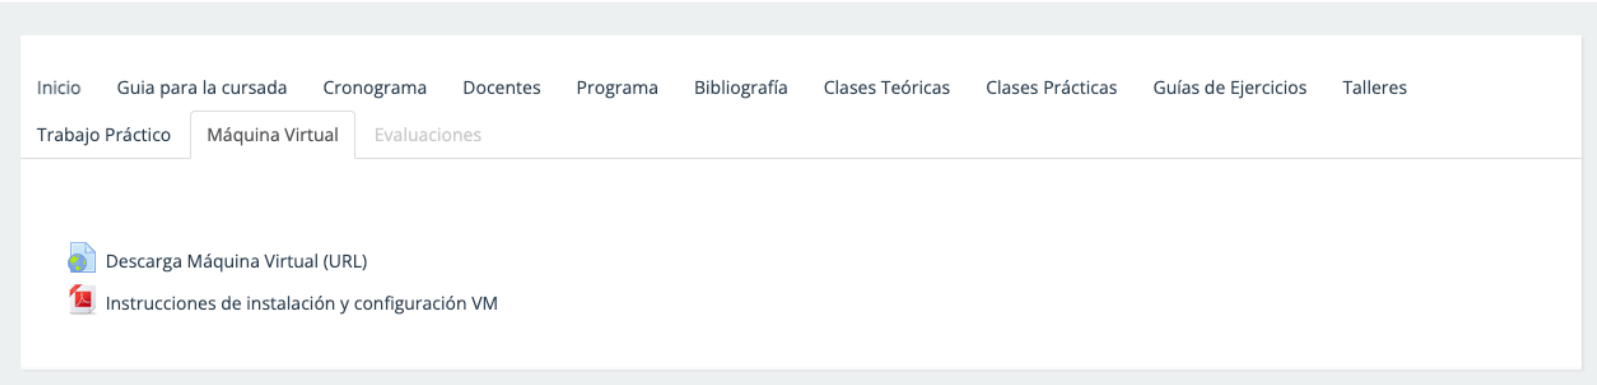

Memoria de Usuario vs Memoria de Kernel

- Tanto `read()` como `write()` escriben en o leen de la memoria de usuario
- El puntero a espacio de usuario puede:
  - ser inválido: puede no haber nada mapeado en esa dirección, o puede haber basura;
  - no estar en memoria (paginado), y el kernel no puede incurrir en *page faults*;
  - ser erróneo o malicioso
- Para estar tranquilos, hay que usar:

```
#include <linux/uaccess.h>

unsigned long copy_to_user(void __user *to, const void *from,
    unsigned long count);
unsigned long copy_from_user(void *to, const void __user *from,
    unsigned long count);
```

Memoria dinámica (kernel)

Existen diversas formas de pedir memoria al sistema cuando estamos ejecutando en modo kernel. Nosotros vamos a ver dos:

kmalloc

Funciones: `void * kmalloc(size_t size, int flags)`, `kfree(void * ptr)`. Solicita un espacio de memoria **físicamente contiguo** de `size` bytes. Devuelve un puntero *virtual* accesible sólo en modo kernel.

vmalloc

Funciones: `void * vmalloc(size_t size)`,`vfree(void * ptr)`. Solicita un espacio de memoria **virtualmente contiguo** de `size` bytes. Devuelve un puntero *virtual* accesible sólo en modo kernel.

Para usarlas, incluir `linux/slab.h`.

Memoria dinámica (kernel)

Existen diversas formas de pedir memoria al sistema cuando estamos ejecutando en modo kernel. Nosotros vamos a ver dos:

kmalloc

Funciones: `void * kmalloc(size_t size, int flags)`, `kfree(void * ptr)`. Solicita un espacio de memoria **físicamente contiguo** de `size` bytes. Devuelve un puntero *virtual* accesible sólo en modo kernel.

Ejemplo de `kmalloc`:

```
#include <linux/slab.h>

// pido 9 bytes
unsigned char* buffer = kmalloc(9, GFP_KERNEL);
```

Sincronización (kernel)

Diversos mecanismos de sincronización. Entre ellos semáforos y *mutexes*.

sempahore

Tipo de datos: `struct semaphore`. Funciones: `sema_init(struct semaphore * sem, int val)`, `down(struct semaphore * sem)`, `down_interruptible(struct semaphore * sem)`,...,`up(struct semaphore * sem)`

spinlock

Tipo de datos: `spinlock_t` Funciones: `spin_lock_init(spinlock_t * lock)`, `spin_lock(spinlock_t * lock)`, `spin_unlock(spinlock_t * lock)`, etc.

Bibliografía

- Device drivers: `https://www.kernel.org/doc/html/v4.19/driver-api/index.html`
- Kernel locking: `https://www.kernel.org/doc/html/v4.19/kernel-hacking/locking.html`
- Libro: `https://lwn.net/Kernel/LDD3/`